논문 발표 (1) - Efficient Estimation of Word Representations in Vector Space

Date	@September 7, 2021
Status	

Word Embeddings (Word2Vec, GloVe)

Efficient Estimation of Word Representations in Vector Space
벡터 공간에서의 단어 표현의 효율적인 추정

▼ paper

Efficient Estimation of Word Representations in Vector Space.pdf

https://drive.google.com/file/d/1nz_GpWxFFUvGUMMwgYAzZvmYExVBlu4w/view?usp=sharing

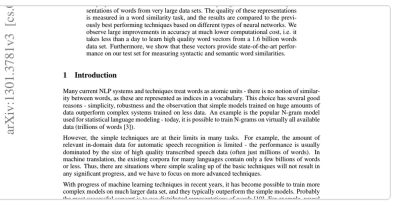

▼ References

[NLP 논문 리뷰] Efficient Estimation Of Word Representations In Vector Space (Word2Vec)

Archive Link Submit Date: Jan 16, 2013 one-hot encoding 방식은 word를 단순하게 표현하는 방법이다. word 자체가 갖는 정보를 담고 있지 않고 단순하게 index만을 담고 있는데, index 역시 word에 내재된 어떤 정보와도 관련이 없다. 본 논문에서는 word vector에 word 자체가 담고 있는 의미를 확실하게 담아내고자 했다.

https://cpm0722.github.io/paper-review/efficient-estimation-of-word-representations-in-vector-space

Word2Vec 그리고 추천 시스템의 Item2Vec

마이크로소프트웨어 AI특집 복간호 기고글 | 개발자들의 마소(마이크로 소프트웨어 잡지)가 다시 발간되었다. 우연히 기회가 되어 재 발간되는 마소에 나의 글을 기고할 수 있게 된 것은 가문의 영광이다. 이 번호 테마는 개발자의 인공지능(AI)이다. 글 쓸 때마다 느끼지만, 가장 좋은 학습 방

https://brunch.co.kr/@goodvc78/16

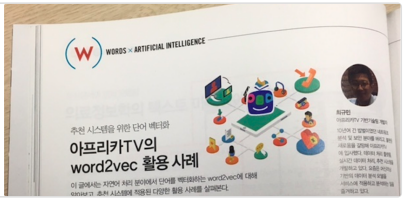

05-2: Text Representation II - Distributed Representation Part 2 (Word2Vec)

고려대학교 산업경영공학과 일반대학원Unstructured Data Analysis05_Text_Representation_II_Distributed Representation_Part_2_KorWord2Vec, CBOW, Skip-gram, Gradient ascenthttps:/...

https://youtu.be/s2KePv-OxZM

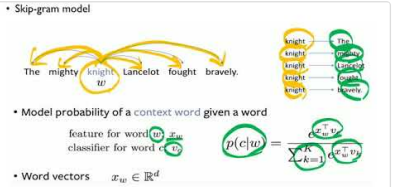

[논문 번역] Efficient Estimation of Word Representations in Vector Space 번역

Word2Vec 관련 논문을 직역한 것입니다. (의역이 아닙니다!) 짧은 영어라 오역이 있을 수 있으니 발견시 피드백 부탁드립니다. 초록 우리는 대량의 데이터로부터 계산된 단어의 연속적인 벡터 표현을 위한 새로운 모델 구조를 제안한다. 이 표현들의 성능은 단어 유사도로 측정되며 이 결과

https://medium.com/@mldevhong/efficient-estimation-of-word-representations-in-vec

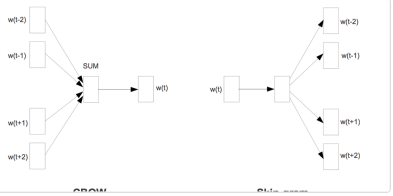

개념 요약

- 해당 논문 발표 전까지 사용되던 NNLM(Neural Net Language Model)을 기반으로 대량의 문서 코퍼스를 엄청난 학습 속도와 성능을 개선한 SOTA 수준의 혁신적인 자연어 처리 기술이다.
- distributed representation
  - 분포 가설(distributional hypothesis)를 이용한다.
- 간단한 FFN(Feed Forward Network)을 구현하여 은닉층의 값을 그 단어를 설명하는 벡터 값으로 사용한다.
- 학습 결과 벡터로 표현된 단어들 중 비슷한 단어들은 벡터 공간 내에서 가까운 곳에 위치하게 된다.
- 단어를 벡터로 표현했기 때문에 단어(벡터) 끼리의 연산이 가능하다.

Model Architectures

- 여러 모델들을 비교하기 위해 computational complexity 를 정의한다.

$$\text{training complexity} = E \times T \times Q$$

  - E: number of epochs
  - T: number of training dataset
  - Q: 모델에서 specific 하게 정의된 value

- 기호 정리
  - N: input word 갯수
  - V: vocabulary size
  - D: word representation dimension
  - H: hidden layer size

Feedforward Neural Net Language Model (NNLM)

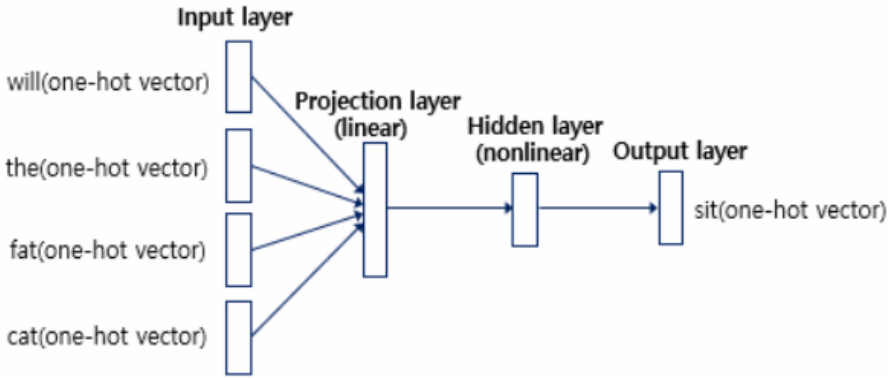

- 일반적인 feed forward neural network 를 사용한 language model 이다.
- 이전 단어들 중 N 개의 word에 대한 one-hot encoding 을 input 으로 받는다.
- computational complexity

$$Q = N \times D + N \times D \times H + H \times V$$

- 위 수식에서 가장 부하가 큰 연산은 hidden layer 에서 output을 만들어내는 연산인 $H \times V$ 이다.
- 하지만 이는 hierarchical softmax 를 사용하게 되면 $H \times \log_2 V$ 로 연산량을 줄일 수 있다.
- 이 경우 가장 부하가 큰 연산은 projection layer 에서 hidden layer를 만들어내는 연산인 $N \times D \times H$ 이다.

Recurrent Neural Net Language Model (RNNLM)

- RNN 을 사용한 Language Model 이다.
- RNN의 경우에는 projection layer 를 제거한다.
- 또한 고정된 개수의 word만을 input 으로 받는 NNLM 과 달리 이전의 모든 word들에 대한 정보를 recurrent 하게 hidden layer 에 담는다.
- computational complexity

$$Q = H \times H + H \times V$$

  - D 와 H 를 동일하게 만들었기 때문에 위와 같은 수식이 된다.
  - NNLM 과 마찬가지로 hierarchical softmax 를 사용하면 $H \times V$ 를 $H \times \log_2 V$ 로 줄일 수 있다.
  - 이 경우 가장 부하가 큰 연산은 $H \times H$ 이다.

New Log-linear Models

- computational complexity 를 줄이기 위해 2가지 단계를 제안한다.
  - CBOW (Continuous Bag-of Words)
  - Skip-gram
- 해당 모델들은 활성화 함수가 없는 네트워크 구조 (linear Neuron) 이다.
- 기존에 사용되던 모델에 비해 계산 복잡도를 최소화하는 모델이다.

CBOW

- 주변 단어를 입력으로 사용하고 중심 단어를 예측하는 모델을 생성한다.

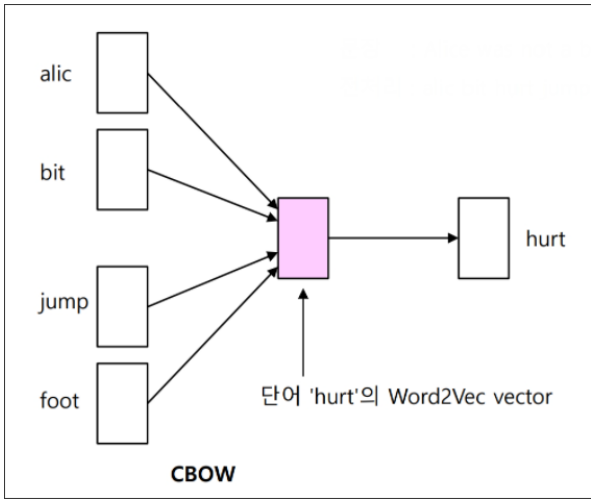

- NNLM 에서 hidden layer 를 제거한 구조이다.

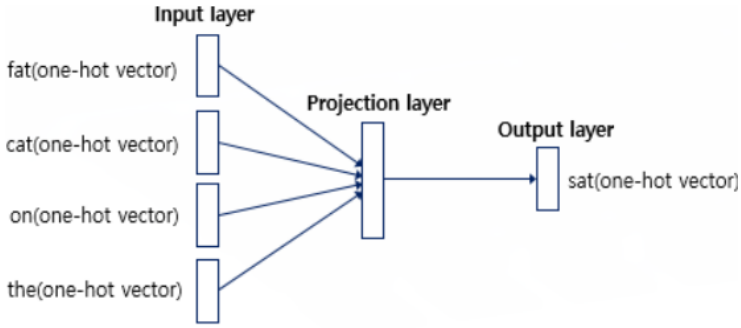

- NNLM 이 이전 단어들을 사용해 다음 단어를 예측한 것과 달리 양방향의 단어를 사용하여 예측을 진행한다.
- computational complexity

$$Q = N \times D + D \times \log_2 V$$

  - hierarichcial softmax 를 사용한다는 가정 하에 가장 연산량이 많이 소요되는 hidden layer 를 제거해 전체 연산량을 줄였다.
  - NNLM 에서는 여러 word embedding vector를 하나의 vector로 압축하기 위해 hidden layer 를 사용했다.
  - CBOW 에서는 이를 non-linear layer 를 거치지 않고 단순하게 평균을 내게 된다.

Skip-gram

- 중심 단어를 입력으로 사용하고 주변 단어를 예측하는 모델을 생성한다.

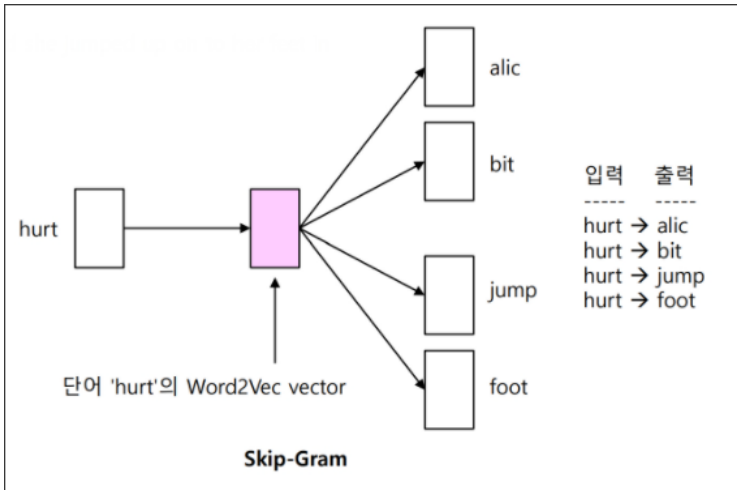

- Skip-gram 은 input word vector를 평균내지 않고 온전히 사용하기 때문에 등장 빈도가 낮은 단어들에 대해 CBOW 대비 train 효과가 크다는 장점이 있다.
- computational complexity

$$Q = C \times (D + D \times \log_2 V)$$

  - C: 예측할 단어의 개수과 관련된 값
- CBOW 보다 Skip-gram이 gradient flow 관점에서 더 좋은 성능을 나타낸다.
  - CBOW 는 하나의 단어를 가지고 주변 단어들에게 gradient 를 전달한다.

- Skip-gram 은 주변 단어들의 모든 gradient 를 하나의 단어가 전달받게 되므로 해당 방식이 performance 가 더 좋다.

수행 과정

- 다음과 같은 문장이 있다고 가정하자.
  - "I love you very much."
- 중심 단어(center word)의 주변 단어(context word)를 이용하여 해당 단어를 표현할 수 있다. (skip-gram 방식)
- 먼저 window size 를 설정하여 단어 집합을 구성한다.
  - window size 를 1로 했을 때, 중심 단어와 좌우의 주변단어 하나씩을 포함하여 총 3개의 단어가 하나의 집합으로 구성된다.
  - I, love, you
  - love you, very
  - you, very, much
- 가운데 단어를 기준으로 학습 데이터를 구성한다.
  - I, love, you
    - `love → I`
    - `love → you`
  - love you, very
    - `you → love`
    - `you → very`
  - you, very, much
    - `very → you`
    - `very → much`
- 이와 같은 학습 데이터를 사용하여 FFN 을 학습 시킨다.
- 학습된 FFN의 hidden layer 의 값을 해당 단어의 벡터(vector) 값으로 사용한다.

단어 사이의 연산

- 단어를 벡터로 표현했기 때문에 단어 간의 연산이 가능하다.

```
vector("King") - vector("Man") + vector("Woman") = "Queen"
```

논문 구현 방법

- 문장 데이터를 불러온다.
- 문장 데이터에 대해 전처리를 수행한다.
  - 불용어 처리, stemming 등

- 단어 사전(vocabulary) 를 생성한다.
- 각 문장들을 window size 를 지정하여 단어 집합을 생성한다.
  - trigram 일 경우 3개의 단어 씩 하나의 집합으로 생성됨
- 단어 집합들을 이용하여 학습 데이터를 구축한다.
  - skip-gram 방식을 사용할 경우, 중심 단어를 입력으로 사용하고 2개의 주변 단어를 출력으로 사용하여 학습 데이터를 구축한다.
- 학습 데이터에 있는 단어들을 단어사전을 이용하여 각각 인덱스로 표현해준다.
- 인덱스로 표현한 단어를 one-hot encoding vector 로 표현해준다.
  - 해당 과정은 네트워크에서 `Embedding` layer 를 사용할 경우 생략이 된다.
- FFN(Feed Forward Network) 를 구현한다.
  - 입력층과 출력층의 크기는 단어사전의 크기와 동일하다.
  - 은닉층의 크기는 단어를 표현하는 벡터의 크기로 결정되며 이는 하이퍼파라미터이다.
- 2가지 모델을 생성한다.
  1. 전체 네트워크를 학습하는 모델
  2. 은닉층의 출력을 얻을 수 있는 모델 (단어가 벡터로 변환된 값을 출력)